Regresión Lineal

Felicidades !! Si llegaste hasta aquí, comienza el momento de realizar nuestras primeras predicciones, con el modelo más básico, la regresión lineal

Modelos de regresión lineal

Modelo con datos simulados

$y = \alpha + \beta \cdot x$

Donde: x = 100 valores distribuidos según una $N(1.5, 2.5)$

$y_e = 10 + 3 \cdot x + e$

e : es un componente de error, distribuido según una $N(0, 0.8)$

In [1]:
```
# Importemos nuestras librerías

import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
```

In [2]:
```
# Definimos las variables
x = 1.5 + 2.5 * np.random.randn(100)
e = 0 + 0.8*np.random.randn(100)
y_act = 10 + 3*x + e
```

In [3]:
```
# Creamos nuestro dataframe

x_list = x.tolist()
#y_pred_list = y_pred.tolist()
y_act_list = y_act.tolist()

data = pd.DataFrame({
    "x": x_list,
    "y_actual": y_act_list
})

data.head()
```

Out[3]:

	x	y_actual
0	2.674151	17.408776
1	3.142386	19.003728
2	2.960494	19.970643
3	5.494891	25.313311
4	-0.021528	8.924667

Obteniendo los coeficientes

Debemos estimar el parámetro y como:

$$y = \alpha + \beta \cdot x$$

Dónde:

- $\beta = \frac{\sum_n^i (x_i - \bar{x}) \cdot (y_i - \bar{y})}{\sum_n^i (x_i - \bar{x})^2}$
- $\alpha = \bar{y} - \beta \cdot \bar{x}$

In [4]:
```
# Calculamos el numerado y denominador de Beta

data['beta_numerador'] = (data['x']-np.mean(data['x']))*(data['y_actual']-np.m
ean(data['y_actual']))
data['beta_denominador'] = (data['x']-np.mean(data['x']))**2
```

In [5]:
```
# Obtenemos el parámetro beta
beta = sum(data['beta_numerador']) / sum(data['beta_denominador'])
# Con Beta, calculamos alpha
alpha = np.mean(data['y_actual']) - beta * np.mean(data['x'])
# Revisemos los valores
alpha, beta
```

Out[5]:
```
(9.916619444717842, 3.0412050601865945)
```

El modelo obtenido por regresión es:

$$y = 10.009211614499218 + 2.912666370161308 \cdot x$$

Así entonces podemos crear una predicción al dataset

In [6]:
```
data['y_prediccion'] = alpha + beta*data['x']
```

In [7]:
```
data.head()
```

Out[7]:

	x	y_actual	beta_numerador	beta_denominador	y_prediccion
0	2.674151	17.408776	3.892752	1.541480	18.049262
1	3.142386	19.003728	8.087880	2.923407	19.473258
2	2.960494	19.970643	8.704831	2.334497	18.920089
3	5.494891	25.313311	44.847404	16.502301	26.627708
4	-0.021528	8.924667	7.777697	2.114453	9.851149

In [8]:
```
## Obtengamos algunas métricas para saber como está nuestro modelo
from sklearn.metrics import mean_squared_error, r2_score
```

In [9]:
```
mean_squared_error(data['y_actual'], data['y_prediccion'])
```

Out[9]:
```
0.5990132148836878
```

In [10]:
```
r2_score(data['y_actual'], data['y_prediccion'])
```

Out[10]:
```
0.9891214060483692
```

In [11]:
```
## Realizemos una visualización gráfica

plt.plot(data['x'], data['y_actual'], 'go')
plt.plot(data['x'], data['y_prediccion'], 'ro')
plt.title('Valores actuales vs predichos');
```

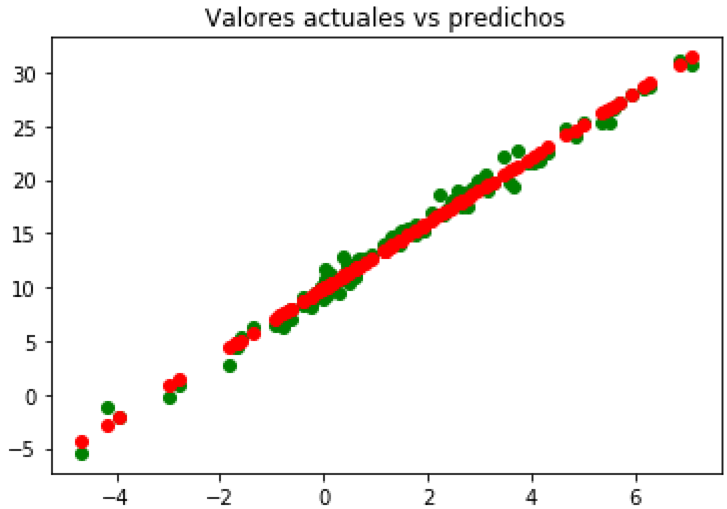

El paquete statsmodel para regresión lineal simple

Hagamos una regresión lineal en ventas de un producto versus la publicidad en TV

In [12]:
```
data = pd.read_csv('/Users/fsanmartin/python-ml-course-master/datasets/ads/Adv
ertising.csv')
data.head()
```

Out[12]:

	TV	Radio	Newspaper	Sales
0	230.1	37.8	69.2	22.1
1	44.5	39.3	45.1	10.4
2	17.2	45.9	69.3	9.3
3	151.5	41.3	58.5	18.5
4	180.8	10.8	58.4	12.9

In [13]:
```
## Importamos la librería

import statsmodels.formula.api as smf
```

In [14]:
```
linear_model = smf.ols(formula='Sales~TV', data=data).fit()
```

In [15]:
```
linear_model.params
```

Out[15]:
```
Intercept    7.032594
TV           0.047537
dtype: float64
```

El modelo lineal predictivo sería: $Sales = 7.032594 + 0.047537 \cdot TV$

In [16]:
```
# Veamos el r2 y el r2 ajustado

linear_model.rsquared, linear_model.rsquared_adj
```

Out[16]: (0.611875050850071, 0.6099148238341623)

In [17]:
```
# También se puede revisar un resumen de un montón de estadísticos
linear_model.summary()
```

Out[17]:

OLS Regression Results

Dep. Variable:	Sales	**R-squared:**	0.612
Model:	OLS	**Adj. R-squared:**	0.610
Method:	Least Squares	**F-statistic:**	312.1
Date:	Fri, 06 Mar 2020	**Prob (F-statistic):**	1.47e-42
Time:	16:32:51	**Log-Likelihood:**	-519.05
No. Observations:	200	**AIC:**	1042.
Df Residuals:	198	**BIC:**	1049.
Df Model:	1		
Covariance Type:	nonrobust		

	coef	**std err**	**t**	**P>|t|**	**[0.025**	**0.975]**
Intercept	7.0326	0.458	15.360	0.000	6.130	7.935
TV	0.0475	0.003	17.668	0.000	0.042	0.053

Omnibus:	0.531	**Durbin-Watson:**	1.935
Prob(Omnibus):	0.767	**Jarque-Bera (JB):**	0.669
Skew:	-0.089	**Prob(JB):**	0.716
Kurtosis:	2.779	**Cond. No.**	338.

Warnings:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

¿Y cómo utilizamos el modelo para predecir? Hagamoslo!

In [18]:
```
sales_pred = linear_model.predict(pd.DataFrame(data['TV']))
sales_pred.head()
```

Out[18]:
```
0    17.970775
1     9.147974
2     7.850224
3    14.234395
4    15.627218
dtype: float64
```

In [19]:
```
# Revisemos un gráfico con los valores reales vs los predichos

data.plot(kind="scatter", x = 'TV', y = 'Sales')
plt.plot(pd.DataFrame(data['TV']), sales_pred, c='red', linewidth=2);
```

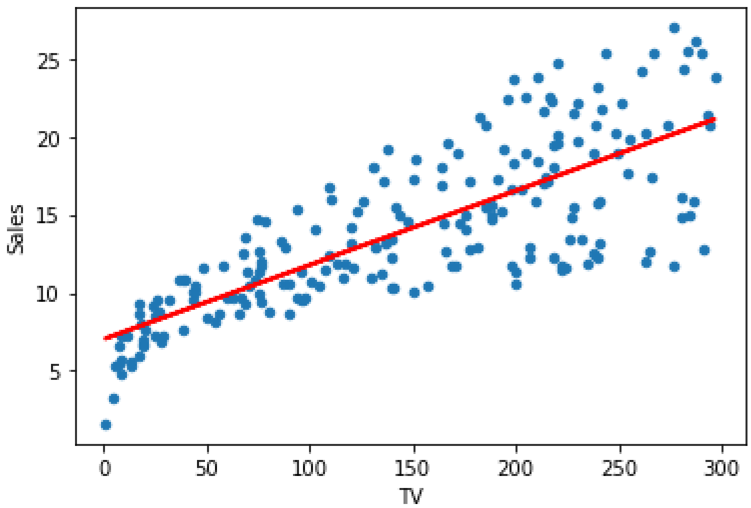

El paquete statsmodel para regresión lineal múltiple

Hagamos una regresión lineal en ventas de un producto versus la publicidad en todos los medios del data set

In [20]:
```
data.columns
```

Out[20]:
```
Index(['TV', 'Radio', 'Newspaper', 'Sales'], dtype='object')
```

In [21]:
```
linear_model_mp = smf.ols(formula='Sales~TV+Radio+Newspaper', data=data).fit()
```

In [22]:
```
linear_model_mp.summary()
```

Out[22]:

OLS Regression Results

Dep. Variable:	Sales	**R-squared:**	0.897
Model:	OLS	**Adj. R-squared:**	0.896
Method:	Least Squares	**F-statistic:**	570.3
Date:	Fri, 06 Mar 2020	**Prob (F-statistic):**	1.58e-96
Time:	16:32:51	**Log-Likelihood:**	-386.18
No. Observations:	200	**AIC:**	780.4
Df Residuals:	196	**BIC:**	793.6
Df Model:	3		
Covariance Type:	nonrobust		

	coef	**std err**	**t**	**P>|t|**	**[0.025**	**0.975]**
Intercept	2.9389	0.312	9.422	0.000	2.324	3.554
TV	0.0458	0.001	32.809	0.000	0.043	0.049
Radio	0.1885	0.009	21.893	0.000	0.172	0.206
Newspaper	-0.0010	0.006	-0.177	0.860	-0.013	0.011

Omnibus:	60.414	**Durbin-Watson:**	2.084
Prob(Omnibus):	0.000	**Jarque-Bera (JB):**	151.241
Skew:	-1.327	**Prob(JB):**	1.44e-33
Kurtosis:	6.332	**Cond. No.**	454.

Warnings:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

In [23]:
```
linear_model_mp.params
```

Out[23]:
```
Intercept    2.938889
TV           0.045765
Radio        0.188530
Newspaper   -0.001037
dtype: float64
```

Estos datos obtenidos, nos indican que el periódico es una variable que empeora el modelo, y por qué? A qué se relaciona esto?

Este es un caso típico de problema de **multicolinealidad**. Para solucionar este problema lo analizamos con el **factor de inflación de la varianza (VIF)**.

Tenemos 3 casos:

- VIF = 1 : Las variables no están correlacionadas
- VIF < 5 : Las variables tienen una correlación moderada y se pueden quedar en el modelo
- VIF > 5 : Las variables están altamente correlacionadas y deben desaparecer del modelo

Machine learning - Proceso generalizado para aprendizaje supervisado

Es momento de que hagamos un proceso de machine learning con sus fases, es importante recordar que este proceso se puede abstraer para ser aplicable e la mayoría de las casos, donde lo único que pudiese cambiar es el algoritmo.

En este caso en particular utilizaremos una regresión lineal

Vamos entonces!!

1. Dividir la Data (muestra)

El primer paso es dividir nuestra muestra en dos grupos:

1. **Entrenamiento**: de donde generamos una aproximación funcional.
2. **Validación**: donde ponemos a prueba nuestra aproximación funcional a nuevos datos.

Es importante saber reconocer que tenemos:

- Un vector objetivo (que es la variable a apredecir, en este caso serían las ventas *Sales*). También se conoce como la variable dependiente
- Y una matriz de atributos, que vendrían siendo todas las demás columnas de nuestro dataframe (en este caso serían las publicidades en *TV, Radio, Newspaper*). También se conocen como variables independientes

Importando módulos Para realizar machine learning utilizaremos **scikit-learn**, una librería con una amplia gama de funciones y modelos para simplificar el flujo de trabajo

In [26]:
```
# importamos train_test_split
from sklearn.model_selection import train_test_split

df = data
```

In [27]:
```
# separemos los vectores a trabajar
y_vec= df.loc[:, 'Sales'] # vector de respuesta
X_mat = df.drop('Sales', axis=1) # matriz de atributos
```

In [28]:
```
# dividimos la muestra en entrenamiento y validación
X_train, X_test, y_train, y_test = train_test_split(X_mat, y_vec, test_size=.3
0, random_state=7785)

# Test_size: nos indica el porcentaje a considerar para la muestra de validaci
ón,
# en este caso 0.3 es qeuivalente al 30% de la muestra para validación
# Random_state: es nuestra semilla generadora. lo recuerdan?
```

In [29]:
```
# Revisamos las dimensiones de los conjuntos
X_train.shape
```

Out[29]: (140, 3)

In [30]:
```
y_train.shape
```

Out[30]: (140,)

In [31]:
```
X_test.shape
```

Out[31]: (60, 3)

In [32]:
```
y_test.shape
```

Out[32]: (60,)

In [33]:
```
X_test.head()
```

Out[33]:

	TV	Radio	Newspaper
51	100.4	9.6	3.6
165	234.5	3.4	84.8
170	50.0	11.6	18.4
137	273.7	28.9	59.7
35	290.7	4.1	8.5

X_test: es nuestra matriz de atributos de validación, si se dan cuenta, falta la variable "Sales". Entonces la idea es utilizar los datos de esta matriz de para predecir la variable "Sales", como también tenemos *y_test* podemos comparar los resultados para medir el error de nuestro algoritmo.

In [35]:
```
y_test.head()
```

Out[35]:
```
51     10.7
165    11.9
170     8.4
137    20.8
35     12.8
Name: Sales, dtype: float64
```

2. Entrenar el modelo

Para esto, necesitamos escoger un algoritmo a utilizar.

En este caso, implementaremos una regresión lineal (en scikit learn es: *LinearRegresion*), donde específicaremos que deseamos incluir un parámetro para el intercepto y deseamos **normalizar** las variables. ¿Recuerdan lo que es normalizar? Si es así, entonces ¿por qué deberíamos normalizar las variables?

In [36]:
```
# importar el modulo LinearRegression de sklearn
from sklearn import linear_model

model_1 = linear_model.LinearRegression(fit_intercept=True, normalize=True)  #
inicializando objeto
model_1
```

Out[36]:
```
LinearRegression(copy_X=True, fit_intercept=True, n_jobs=None, normalize=Tru
e)
```

In [37]:
```
# Una vez inicializado el objeto con nuestras especificaciones, podemos entren
ar el modelo con .fit

model_1.fit(X_train, y_train) # entrenando el modelo inicializado con el set d
e entrenamiento (x,y)train
```

Out[37]:
```
LinearRegression(copy_X=True, fit_intercept=True, n_jobs=None, normalize=Tru
e)
```

In [38]:
```
model_1.coef_ # Obtener los coeficientes estimados mediante el ajuste del mode
lo
```

Out[38]:
```
array([ 0.04761283,  0.18838599, -0.00332285])
```

In [39]:
```
model_1.intercept_  # valor del intercepto
```

Out[39]:
```
2.7860984182508925
```

In [40]:
```
model_1.normalize
```

Out[40]:
```
True
```

3. El último paso es generar los puntajes predichos ( ) con .predict

In [41]:
```
model_1_yhat = model_1.predict(X_test) # predecir con el set de atributos de t
esting
model_1_yhat
```

Out[41]:
```
array([ 9.36296967, 14.31004111,  7.29087685, 21.06371042, 17.37128602,
       19.99572235, 16.33849172, 16.7527717 ,  8.05323174,  9.70629967,
       12.39019687, 23.44924954, 11.11765261, 15.67116496, 15.21124759,
       14.9133089 , 15.12418957,  9.02616756, 16.52370167, 17.58539649,
       13.44691966, 13.22424932, 17.29641475, 14.85342399,  7.06972372,
        9.88201077, 14.30708621, 21.91967223, 12.49616054,  8.30316717,
       23.98133537, 10.14441863, 11.52615995, 12.76816742, 18.22559179,
        5.94997629, 14.30769895, 11.32113798, 12.83281736, 13.54757518,
       12.94429255, 17.23111201,  6.43705079,  4.32075013, 19.1987887 ,
       15.56424749, 12.24224814, 15.42824665,  4.32808572, 17.37706678,
       13.8516619 ,  8.39549857, 16.84804274, 11.55025652,  6.24511148,
       20.63285931, 14.23842678,  5.63904766, 15.8980664 , 18.4263597 ])
```

Listo !! .... Espera, espera. Aun falta un último paso: ¿Qué tan bueno es el modelo?

Medir desempeño

- Se comprueba mediante las métricas.
- Para el caso de la regresión lineal, nuestro objetivo es encontrar una función candidata que minimice las pérdidas, medidas en el Error Cuadrático Promedio.

In [ ]:
```
# Importamos la librería de métricas de desempeño en Machine Learning

from sklearn.metrics import mean_squared_error, r2_score
```

In [43]:
```
# Evaluar qué tan bien se desempeñó el modelo
print(mean_squared_error(y_test, model_1_yhat)) # error cuadratico medio
print(r2_score(y_test, model_1_yhat)) # r cuadrado
```

```
2.6533397673973425
0.8685838560414693
```

In [47]:
```
## Hagamos una pequeña gráfica de barras, donde comparamos los valores obtenid
os vs los reales

preds_1 = pd.DataFrame({'valor_real':y_test, 'predicción':model_1_yhat})

preds_1.sample(frac=0.5).plot(kind='bar',figsize=(18,8))
plt.grid(linewidth='2')
plt.grid(linewidth='2')
plt.grid(None)
plt.show()
```

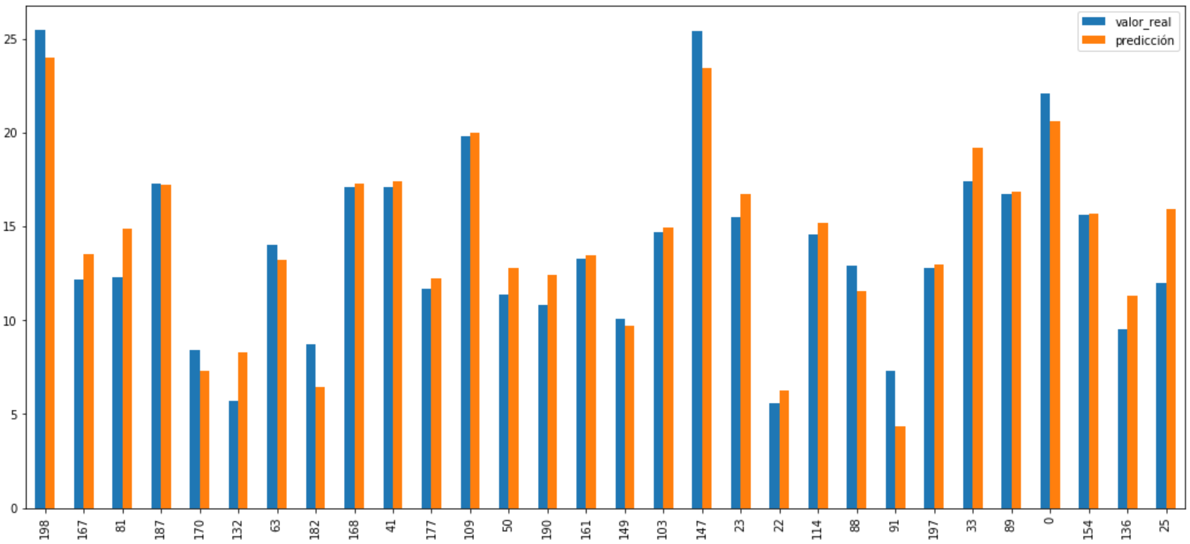

Felicidades, este es tu primer modelo de Machine Learning!

Una última recomendación es: utiliza este modelo, siempre y cuando la variable que quieras predecir sea **cuantitativa**

In [ ]: